Projeto C1 — Classificação de Imagens com IA

Bianca Huwer Santos
Gabriela de Oliveira Marino

Vitória
2026

FUNDAÇÃO DE ASSISTÊNCIA E EDUCAÇÃO – FAESA
FACULDADES INTEGRADAS ESPÍRITO-SANTENSES
GRADUAÇÃO EM ENGENHARIAS

BIANCA HUWER SANTOS
GABRIELA DE OLIVEIRA MARINO

Projeto C1 — Classificação de Imagens com IA

Trabalho como requisito parcial à disciplina de Robótica e Sistemas Inteligentes, apresentada às Faculdades Integradas Espírito-santenses sob orientação do Prof. Otávio dos Santos Lube.

VITÓRIA
2026

0.1 Introdução

Este trabalho apresenta o desenvolvimento de um sistema inteligente para a classificação automatizada de modais de transporte, utilizando técnicas de Inteligência Artificial. O objetivo central é criar uma ferramenta capaz de distinguir entre seis categorias fundamentais de veículos: carros, bicicletas, motos, aviões, navios e trens. O projeto passa por todas as etapas do ciclo de vida de uma aplicação de IA:

- **Curação de Dados:** Coleta e organização do *dataset* da plataforma Kaggle.
- **Treinamento:** Utilização da plataforma Teachable Machine para o treinamento supervisionado de uma rede neural.
- **Desenvolvimento Web:** Implementação de uma interface funcional utilizando a biblioteca TensorFlow.js, permitindo que o modelo execute diretamente no navegador do usuário.

A solução desenvolvida visa demonstrar como a IA pode ser aplicada em contextos de logística, monitoramento de tráfego e sistemas de transporte inteligentes, oferecendo uma interação intuitiva e processamento de imagem em tempo real.

0.2 Descrição do Dataset

O conjunto de dados (dataset) utilizado neste projeto foi selecionado a partir da plataforma Kaggle, referência em Ciência de Dados. A escolha deste repositório garante a diversidade necessária para o treinamento de modelos de rede neural.

0.2.1 Composição e Estrutura

O dataset é composto por 4787 imagens, organizadas em seis classes que representam diferentes modais de transporte. A distribuição das amostras por classe é apresentada a seguir:

- Carro: 790 imagens;
- Bicicleta: 800 imagens;
- Moto: 800 imagens;
- Avião: 797 imagens;
- Navio: 800 imagens;
- Trem: 800 imagens.

0.2.2 Justificativa da Escolha

As categorias foram selecionadas para testar a capacidade da IA em diferentes contextos visuais (vias terrestres, aéreas e marítimas). A escolha de classes como Bicicleta e Moto oferece um desafio maior ao modelo por compartilharem formatos semelhantes. Além de uso de fotos do mundo real para melhor validação do modelo.

0.3 Treinamento no Teachable Machine

O treinamento do modelo foi realizado utilizando a plataforma Teachable Machine, que permite a criação de modelos de classificação de imagens de forma intuitiva. Foi criado um novo projeto do tipo Image Project. Em seguida, as imagens do dataset foram carregadas na plataforma, onde separamos de acordo com as classes. Depois do carregamento, o modelo foi treinado utilizando as configurações padrão da ferramenta. Após o treinamento, foram realizados testes diretamente na plataforma, utilizando imagens de validação para verificar o desempenho do modelo na identificação das classes.

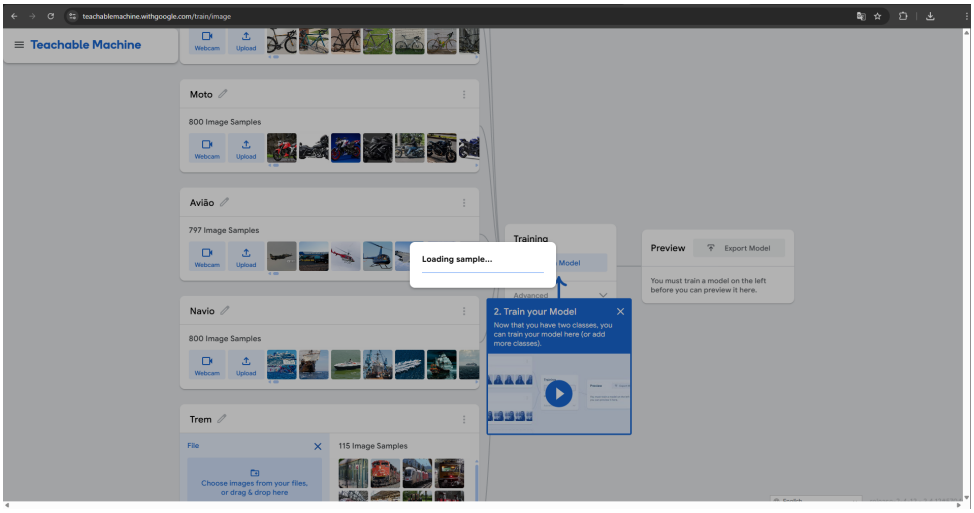

Figura 1 – Carregando as imagens no Teachable Machine

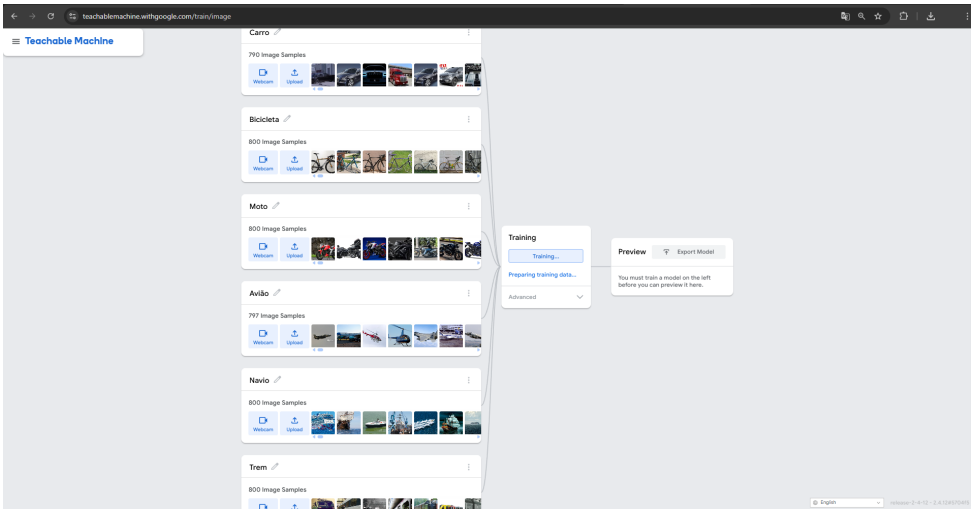

Figura 2 – Classes de imagens definidas no Teachable Machine

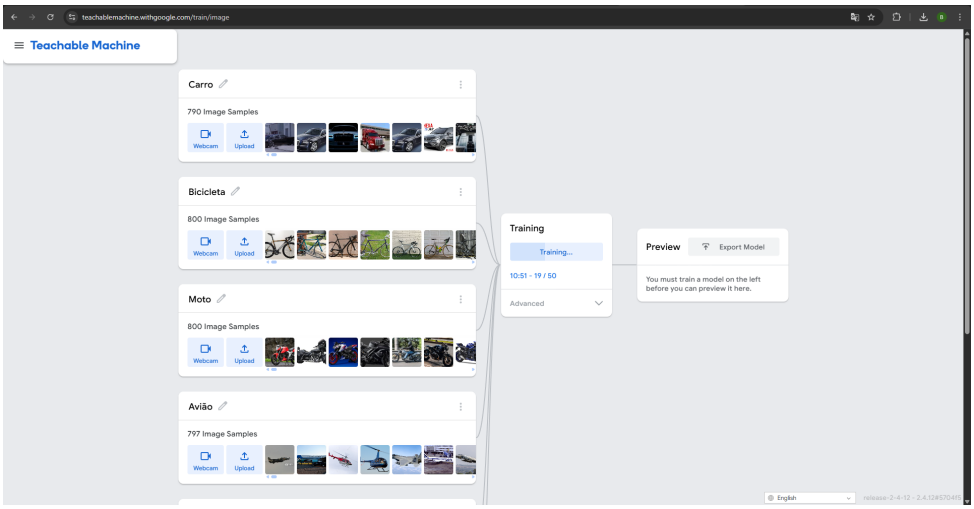

Figura 3 – Treinamento da IA

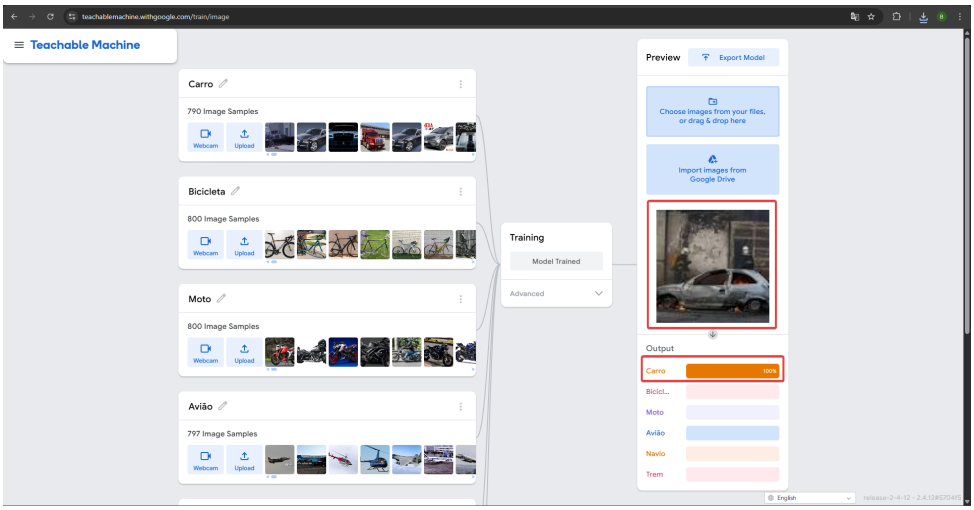

Figura 4 – Teste com uma imagem de carro

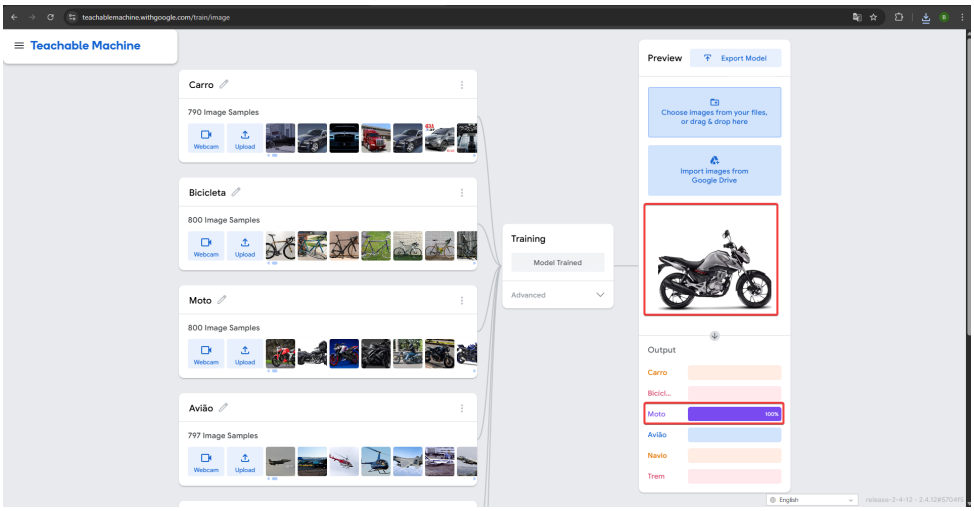

Figura 5 – Teste com uma imagem de moto

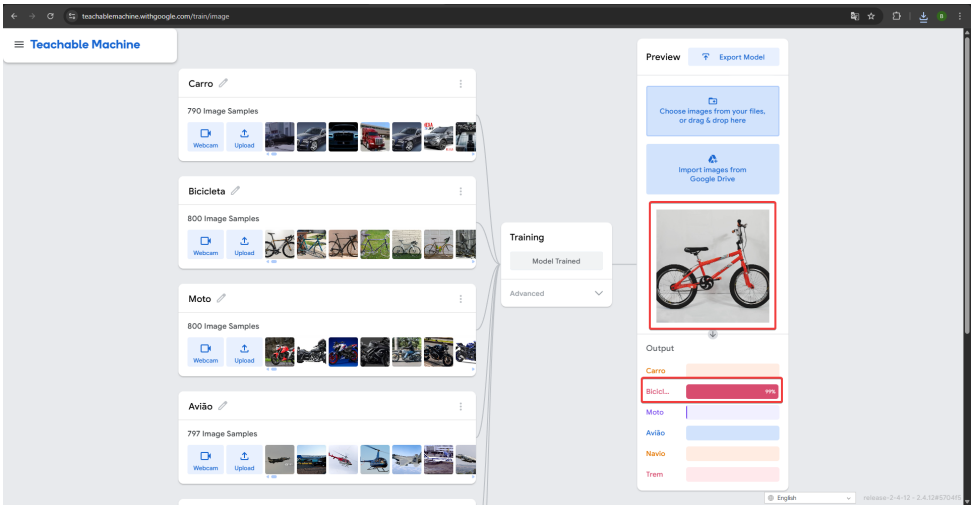

Figura 6 – Teste com uma imagem de bicicleta

0.4 Implementação Web com TensorFlow.js

Nesta etapa, o modelo treinado foi integrado a uma aplicação web responsiva, permitindo que a classificação ocorra localmente no navegador do usuário, garantindo privacidade e velocidade de processamento.

0.4.1 Tecnologias utilizadas

A aplicação foi construída utilizando o que é fundamental do desenvolvimento web, aliado a bibliotecas de Inteligência Artificial:

- **HTML5 & CSS3:** Responsáveis pela estruturação da interface e pelo design moderno e intuitivo.
- **JavaScript (ES6+):** Utilizado para a manipulação do DOM e lógica de interação.
- **TensorFlow.js:** Biblioteca principal que permite a execução de modelos de Machine Learning em hardware cliente (GPU/CPU do navegador).

0.4.2 Estrutura da Aplicação

O projeto foi organizado de forma modular para facilitar a manutenção:

- **index.html**: Ponto de entrada que contém os containers de upload e exibição.
- **style.css**: Camada de estilização que foca na experiência do usuário (UX).
- **script.js**: O "motor"da aplicação, responsável por gerenciar o ciclo de vida da IA.
- **/model**: Diretório local contendo o grafo do modelo (model.json), os pesos binários (weights.bin) e as etiquetas das classes (metadata.json).

0.4.3 Carregamento do Modelo

O carregamento é feito de forma assíncrona através da função tmImage.load(). Para evitar erros de segurança (CORS) e garantir que o modelo esteja pronto antes da primeira interação, a aplicação utiliza uma função init() que pré-carrega os arquivos da pasta local assim que a página é instanciada.

0.4.4 Entrada de Dados

A aplicação oferece uma interface de Upload de Arquivo. O usuário seleciona uma imagem do seu dispositivo, que é lida através da API FileReader do JavaScript. Uma prévia da imagem é exibida instantaneamente na tela, servindo como o *input* visual que será enviado para a rede neural.

0.4.5 Processo de Classificação

Assim que a imagem é carregada no navegador:

- A imagem é convertida em um tensor (formato matemático que a IA entende).
- O método model.predict() processa esses dados através das camadas da rede neural.
- O sistema retorna um array com as probabilidades de todas as classes (Carro, Moto, Bicicleta, Avião, Navio e Trem).
- A aplicação identifica a classe com a maior probabilidade (confiança) e atualiza a interface em tempo real, exibindo o nome do veículo detectado e uma barra de progresso com o nível de certeza do modelo.

0.5 Avaliação do Modelo

Para avaliar o desempenho do modelo, foi aplicada a divisão dos dados seguindo o Princípio de Pareto:

- 80% dos dados foram utilizados para treinamento
- 20% dos dados foram utilizados para teste

O modelo foi treinado novamente utilizando o conjunto de treino e avaliado com o conjunto de teste.

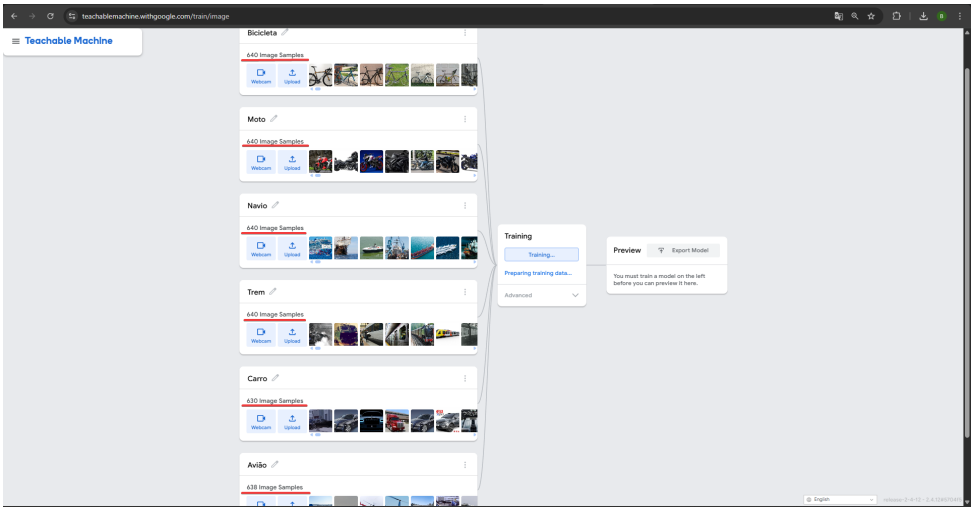

Figura 7 – Novo treinamento da IA (80% treino e 20% teste)

0.5.1 Matriz de Confusão

A tabela abaixo cruza os valores reais das imagens de teste com as predições feitas pelo sistema. Foram testadas 25 imagens por classe, totalizando 150 amostras.

Tabela 1 – Matriz de Confusão

Real \ Predito	Bicicleta	Carro	Moto	Avião	Navio	Trem
Bicicleta	24	0	1	0	0	0
Carro	0	25	0	0	0	0
Moto	0	0	25	0	0	0
Avião	0	0	0	23	2	0
Navio	0	0	0	0	24	1
Trem	0	0	0	0	0	25

0.5.2 Métricas de avaliação

A partir da matriz, calculamos as métricas de precisão, recall e F1-Score:

- **Acurácia Geral:** 97,33%
- **Precisão (Precision):** Indica a confiabilidade das predições positivas. O maior desafio foi na classe Navio (92,3%), devido ao erro onde um navio foi confundido com um trem.
- **Recall (Revocação):** Indica a capacidade do modelo em encontrar todos os itens de uma classe. A classe Avião (92%) apresentou o menor recall, pois duas amostras foram classificadas erroneamente como navios.
- **F1-Score:** A média harmônica entre as métricas anteriores, mantendo-se acima de 0,94 em todas as categorias.

Tabela 2 – Métricas de Avaliação

Classe	Precision	Recall	F1-Score
Bicicleta	100%	96%	0,98
Carro	100%	100%	1,00
Moto	96,15%	100%	0,98
Avião	100%	92%	0,96
Navio	92,30%	96%	0,94
Trem	96,15%	100%	0,98

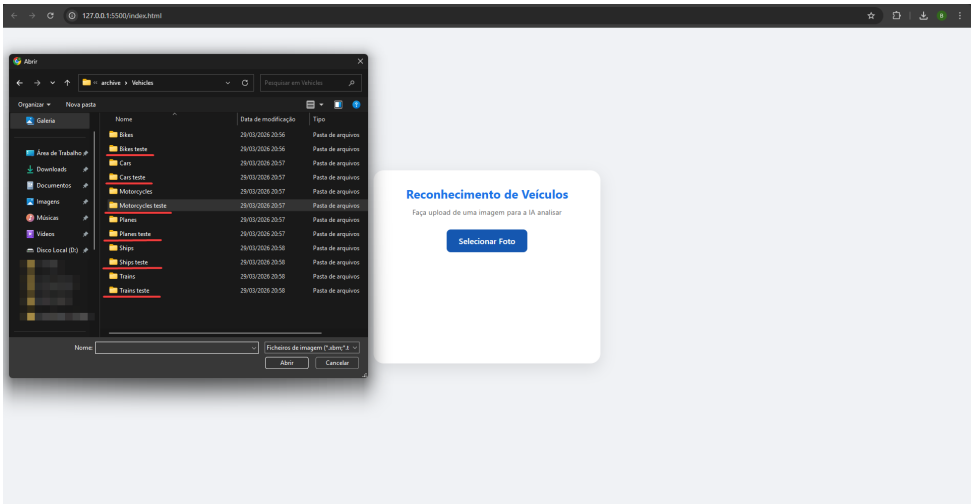

Figura 8 – Demonstração do upload de imagens para processamento pela IA

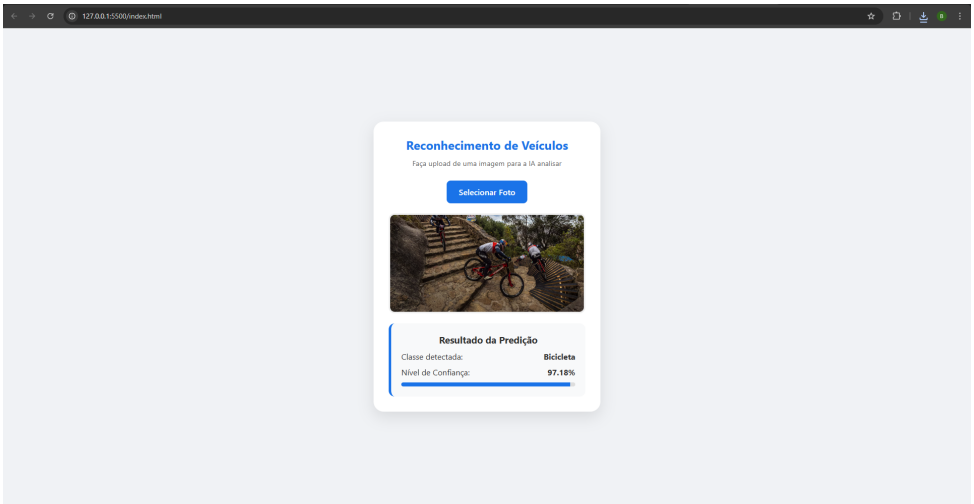

Figura 9 – Resultado da predição do modelo

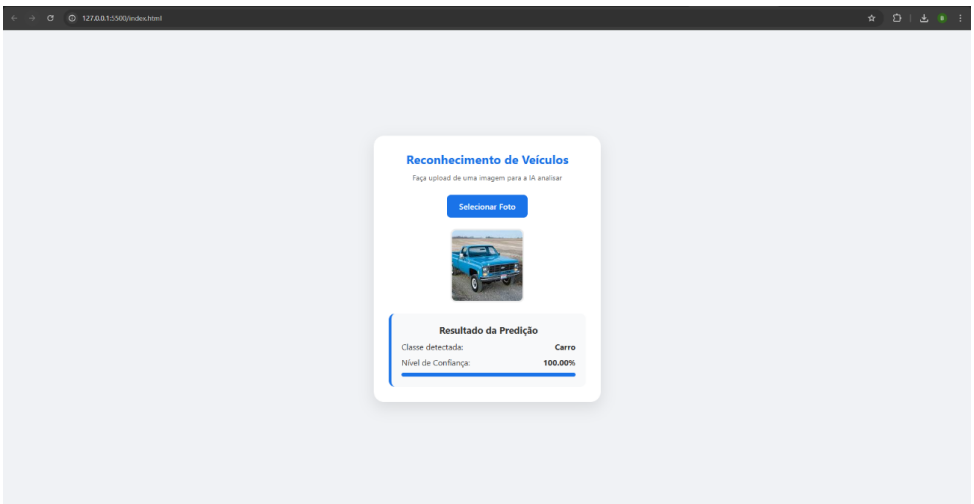

Figura 10 – Resultado da predição do modelo

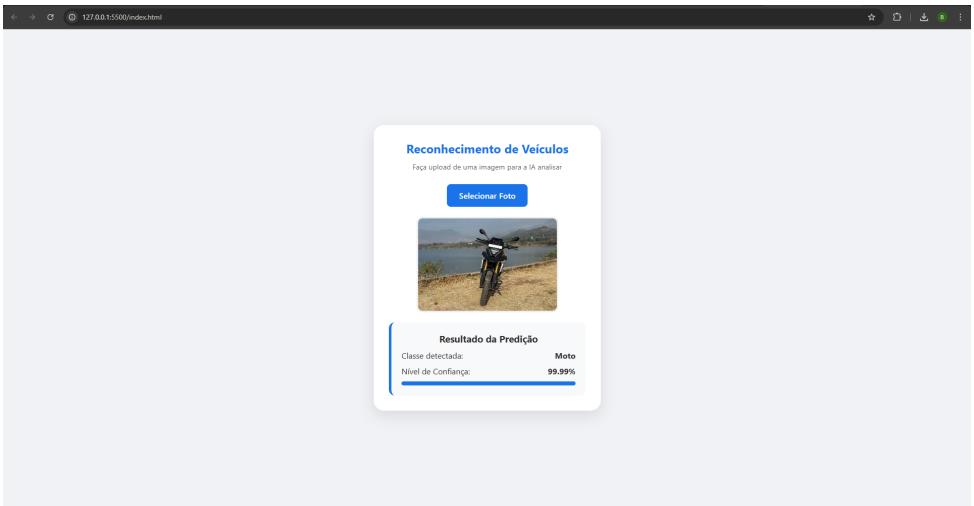

Figura 11 – Resultado da predição do modelo

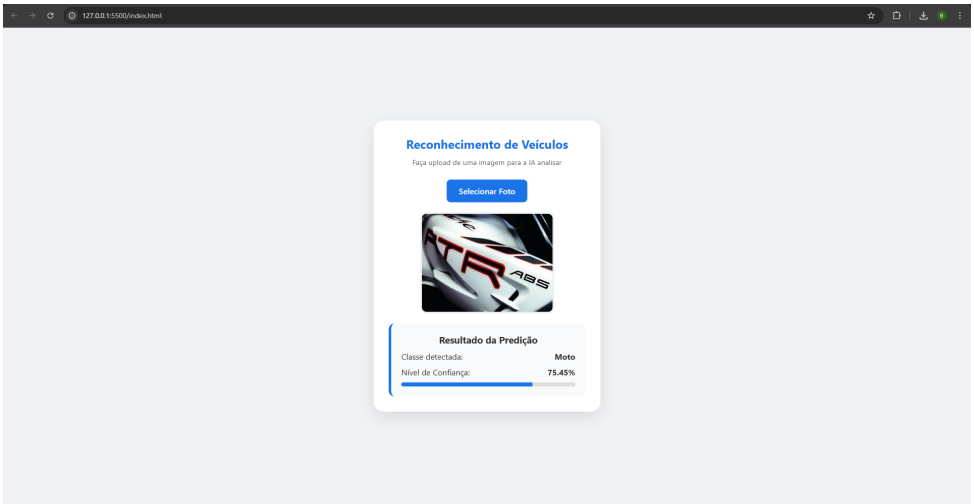

Figura 12 – Resultado da predição do modelo

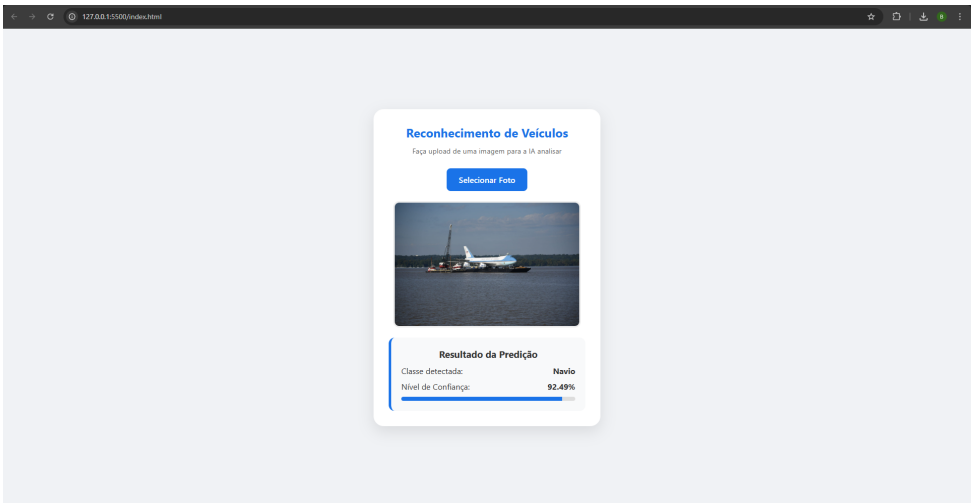

Figura 13 – Resultado da predição do modelo

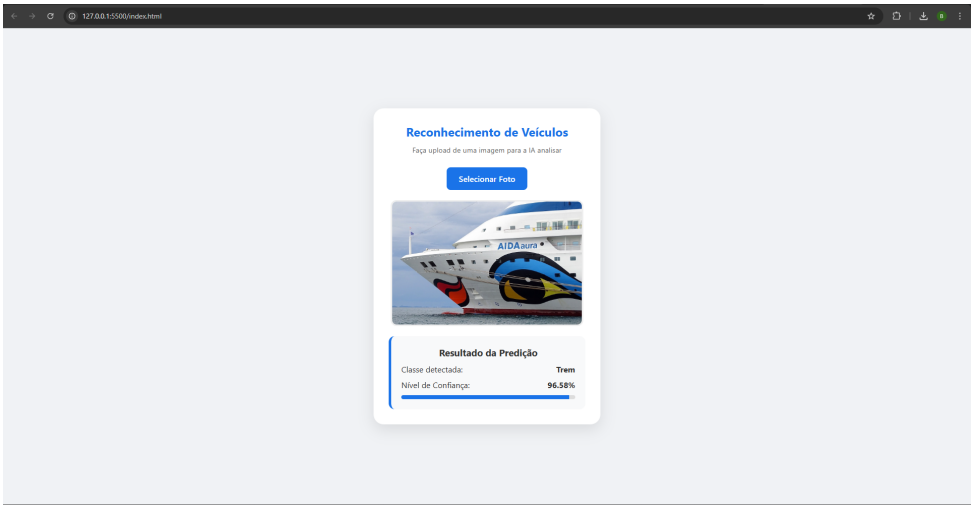

Figura 14 – Resultado da predição do modelo

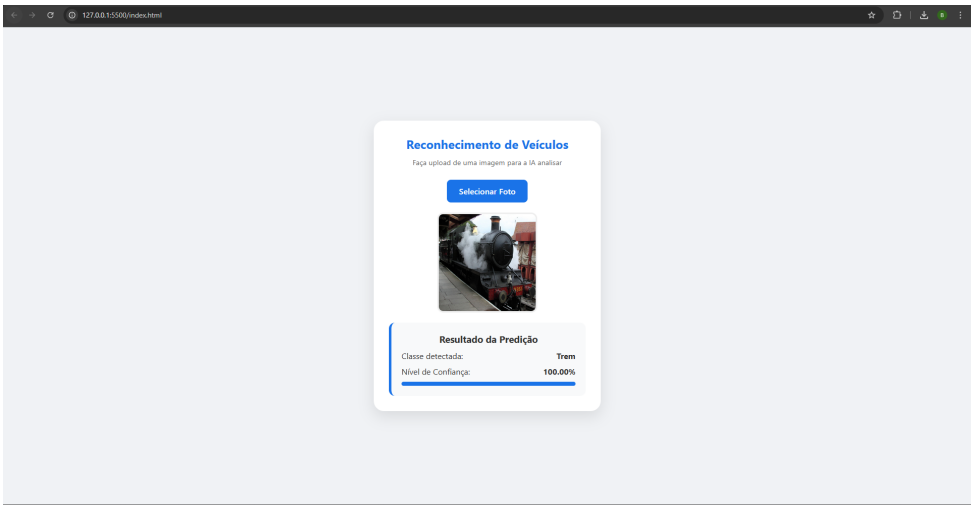

Figura 15 – Resultado da predição do modelo

0.6 Conclusão e Possíveis Melhorias

O projeto demonstrou que a utilização de redes neurais via TensorFlow.js é uma solução viável e eficiente para a classificação de modais de transporte em tempo real. O modelo alcançou um desempenho superior a 97%, provando que a arquitetura do Teachable Machine é capaz de extrair características complexas mesmo com datasets de tamanhos moderados.

0.6.1 Análise dos Erros

Os erros observados (Bicicleta vs. Moto e Avião vs. Navio) ocorreram em classes que compartilham semelhanças visuais:

- **Bicicleta e Moto:** Compartilham o formato do quadro e rodas, dificultando a distinção em ângulos específicos.
- **Avião e Navio:** O modelo parece ter sido influenciado pelo *background* (fundo) das imagens, confundindo o azul do céu com o azul do mar em fotos de longa distância.

0.6.2 Sugestões de Melhorias

Para evoluir o sistema em versões futuras, sugerem-se as seguintes ações:

- **Data Augmentation:** Aplicar técnicas de rotação, brilho e zoom nas imagens de treino para tornar o modelo mais resiliente a diferentes condições de iluminação.
- **Balanceamento de Fundo:** Incluir mais imagens de aviões em solo e navios em portos para que a IA aprenda a focar no objeto e não apenas na cor do cenário (céu/mar).